🤖 Digital Signal Processing

Lab 03: The Machine That Listens (Speech Recognition)

"Teaching sand to think was hard. Teaching it to hear is a whole other dimension."

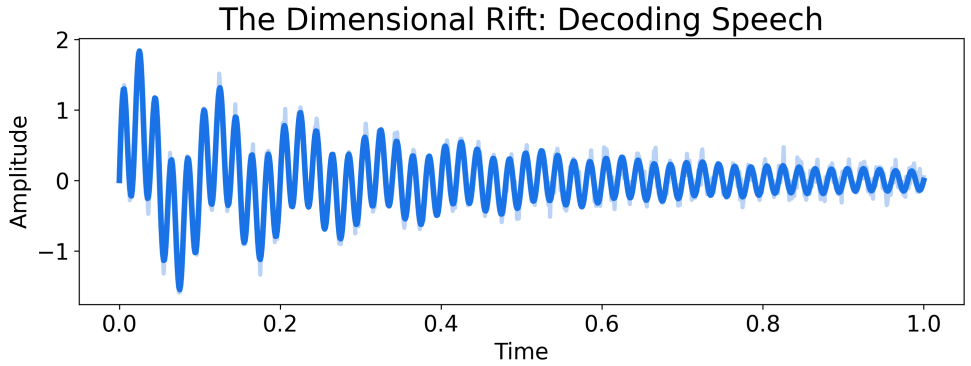

🎯 Mission Objectives

สิ่งที่เราจะค้นหาในวันนี้:

1. **The Big Picture:** แผนผังการทำงานของระบบ Speech Recognition
2. **The Human Ear (Mel Scale):** ทำไม AI ต้องบีบอัดเสียงให้เหมือนหูมนุษย์?
3. **The Visual Brain (CNN):** เปลี่ยนเสียงเป็นภาพ แล้วให้คอมพิวเตอร์ "มอง"
4. **The Output & Softmax:** การแปลงผลลัพธ์ของ AI ให้กลายเป็น % ความมั่นใจ
5. **Data Consistency:** กฎเหล็กของวิศวกรข้อมูล (Data Engineer)

1. The Big Picture: System Architecture

ก่อนที่เราจะลงมือเขียนโค้ด มาดูภาพรวมการเดินทางของข้อมูลกันก่อน

ระบบ AI ไม่ได้ฟังเสียงจากไมโครโฟนแล้วตอบได้ทันที แต่มันต้องผ่านกระบวนการแปลงร่างข้อมูล (Pipeline) หลายขั้นตอน:

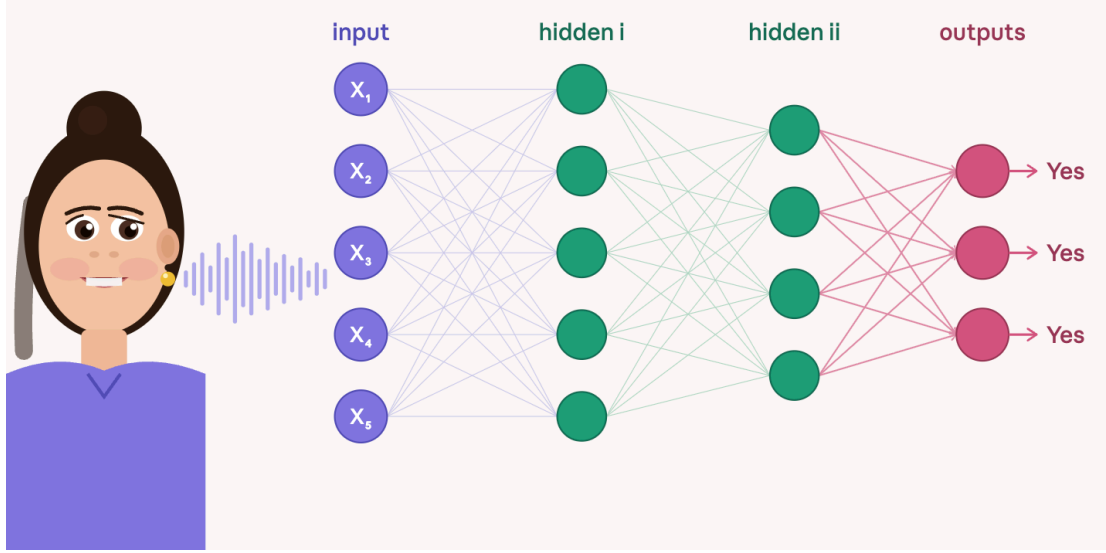

👂 2. Feature Extraction: ทำไมต้อง Mel-Spectrogram?

- สัปดาห์ที่แล้วเรารู้จัก Spectrogram (มิติเวลา vs ความถี่)
- **ปัญหา:** Spectrogram ปกติใช้สเกลความถี่แบบเส้นตรง (Linear) แต่ **หูมนุษย์ไม่ได้ยินแบบนั้น!** * เราแยกความต่างของเสียงต่ำได้ดีมาก แต่แทบแยกเสียงแหลม (10,000Hz กับ 10,100Hz) ไม่ออก
- **ทางแก้ (The Mel Scale):** บีบอัดแกน Y ของ Spectrogram ให้โค้งคล้ายการรับรู้ของมนุษย์ เรียกว่า **Mel-Spectrogram**

> 💡 **[MISSION 2 CLUE]:** > ในงาน Speech Recognition มาตรฐาน เรามักจะแบ่งความถี่ออกเป็น **64 แบนด์ (n_mels = 64)** และตัดข้อมูลทิ้งที่ความถี่สูงสุด **8,000 Hz (fmax = 8000)** เพราะเสียงพูดมนุษย์ส่วนใหญ่ไม่เกินย่านนี้!

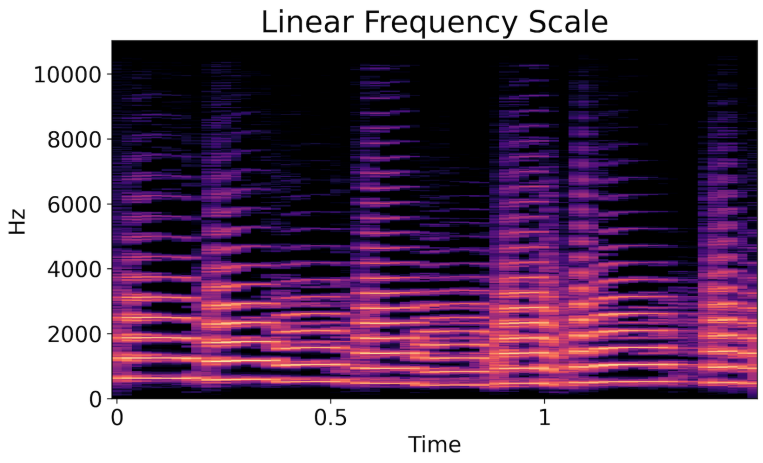

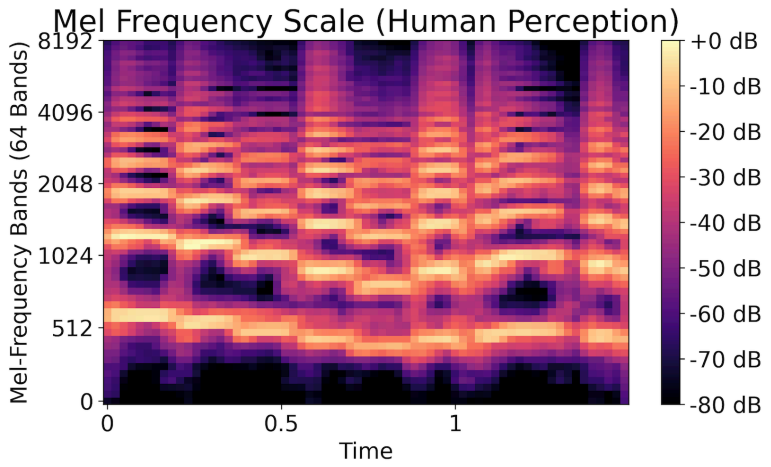

🧠 3. The Brain: Convolutional Neural Network (CNN)

AI ไม่ได้ฟังคลื่นเสียงดิบๆ แต่มัน "มอง" ลวดลายบน Spectrogram

- **CNN** คือโครงข่ายประสาทเทียมที่ถูกสร้างมาเพื่อ **"วิเคราะห์รูปภาพ"**
- มันทำงานโดยการเอา "แว่นขยาย" (Filter) กวาดไปบนภาพ Spectrogram เพื่อหาลวดลาย (Patterns)
  - *จุดที่สว่างวาบ (Burst) อาจแปลว่าพยัญชนะ ก, ต, ป*
  - *เส้นความถี่ที่ลากยาว (Formants) อาจแปลว่าสระ อา, อี, อู*
- ทันทีที่เราเปลี่ยนเสียงเป็นรูปภาพ... เราก็สามารถใช้ AI สแกนภาพระดับโลกมาวิเคราะห์เสียงได้ทันที!

Convolutional Scanning (Filter: 3x3)

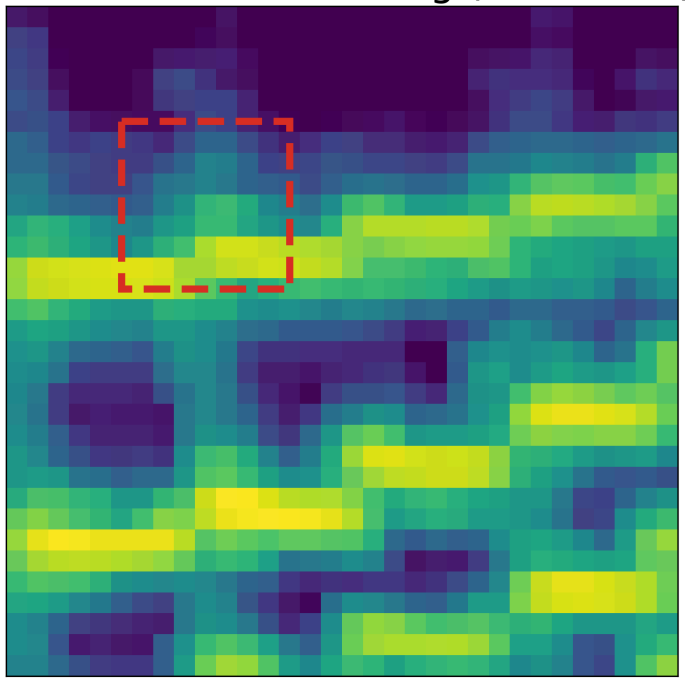

🏗️ 4. Unboxing the Brain: CNN Architecture

โครงสร้างภายในสมองกลที่เราจะสร้างขึ้นใน Lab วันนี้ (Keras Sequential Model)

ข้อมูลจะไหลผ่านชั้นต่างๆ (Layers) เพื่อสกัดคุณลักษณะที่ซับซ้อนขึ้นเรื่อยๆ:

- **Conv2D:** แว่นขยายสแกนหาลวดลายเส้นโค้ง/เส้นตรง
- **MaxPooling2D:** ย่อขนาดภาพลง เพื่อดึงเฉพาะจุดที่เด่นที่สุด (ลดภาระการคำนวณ)
- **Flatten:** ทุบข้อมูล 2 มิติให้แบนเป็นเส้นตรง เพื่อเตรียมส่งให้สมองส่วนตัดสินใจ
- **Dense:** เซลล์ประสาทที่เชื่อมต่อกันทุกทิศทาง ทำหน้าที่สรุปผลและตัดสินใจ

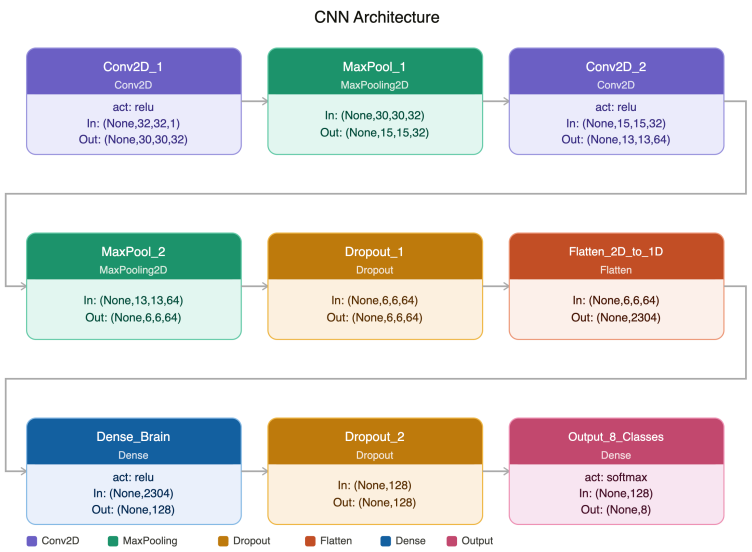

💻 4.5 Code Translation: จากทฤษฎีสู่ภาษา Python

การสร้างสมองกลด้วย Keras (Sequential API)

เราจะจับชั้นสมอง (Layers) มาเรียงต่อกันเป็นชั้นๆ คล้ายแซนด์วิช โดยใช้โครงสร้างข้อมูลแบบ **List** `[ ... ]` ใน Python

```
model = models.Sequential([
    layers.Conv2D(32, 3, activation='relu'), # ชั้นสแกนลวดลาย
    layers.MaxPooling2D(),                   # ชั้นย่อขนาดภาพ
    layers.Flatten(),                        # ชั้นทุบข้อมูลให้แบนเป็น 1D

    # MISSION 3: ชั้นตัดสินใจ (Output)
    layers.Dense(จำนวนเซลล์, activation='ชื่อฟังก์ชัน')
])
```

โค้ดสกัดภาพ (Librosa)

```
S = librosa.feature.melspectrogram(
    y=audio,
    sr=16000,
    n_mels=64,
    fmax=8000
)
```

📊 5. The Output: How AI Makes a Guess

เมื่อ CNN สกัดลวดลายเสร็จ มันจะส่งต่อให้ชั้นสุดท้าย (Output Layer)

- **1. จำนวนเซลล์ประมวลผล (Nodes):** ชั้นสุดท้ายนี้ต้องมีจำนวนเซลล์ **เท่ากับจำนวนคำศัพท์ (Classes)** ที่เราต้องการให้มันทายพอดีเป๊ะ!
- **2. ฟังก์ชันตัดสินใจ (Activation Function):** ผลลัพธ์ดิบๆ จากสมองกลมักเป็นตัวเลขมั่วๆ (เช่น 12.5, -3.2) เราต้องใช้ฟังก์ชันที่ชื่อว่า `softmax`

> 💡 **[MISSION 3 CLUE]:** > **Softmax** คือเวทมนตร์คณิตศาสตร์ที่แปลงตัวเลขมั่วๆ ให้กลายเป็น **"เปอร์เซ็นต์ความน่าจะเป็น"** โดยบังคับให้ผลรวมของทุกคำตอบบวกกันได้ **1.0 (หรือ 100%)** เสมอ

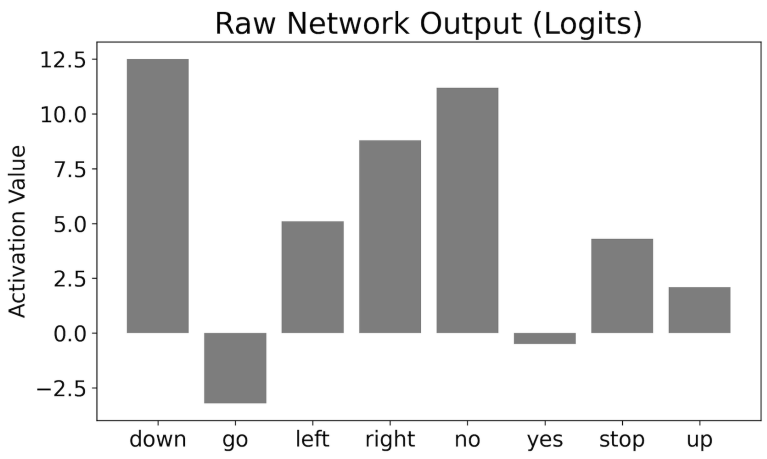

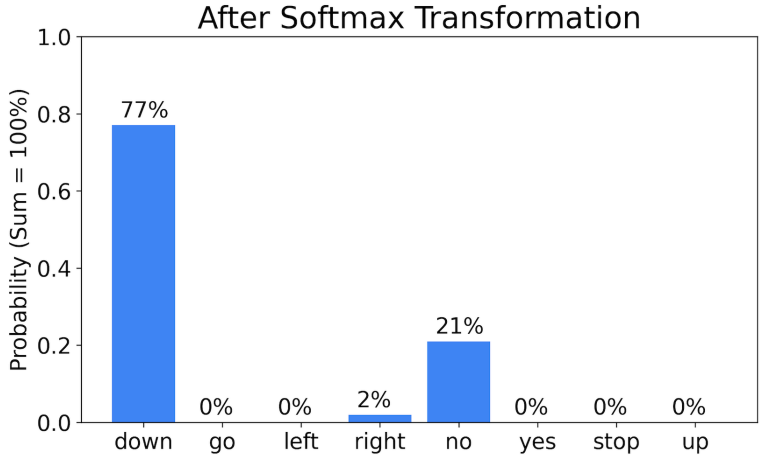

⏳ 6. The Training: Epochs (การเรียนรู้ซ้ำๆ)

มนุษย์ไม่ได้ขี่จักรยานเป็นตั้งแต่ครั้งแรก AI ก็เช่นกัน

- ในการสอนสมองกล เราไม่สามารถให้มันดูข้อมูลแค่รอบเดียวแล้วจบ
- **Epoch (อีพ็อค):** คือรอบของการเรียนรู้ เมื่อ AI ดูข้อมูลเสียง "ครบทั้งหมด 1 ชุด" เราจะนับเป็น 1 Epoch
- เมื่อจบ 1 Epoch AI จะเช็คว่าตัวเองทายผิดไปเท่าไหร่ (Loss) และปรับเส้นใยประสาท (Weights) ให้เก่งขึ้นในรอบต่อไป

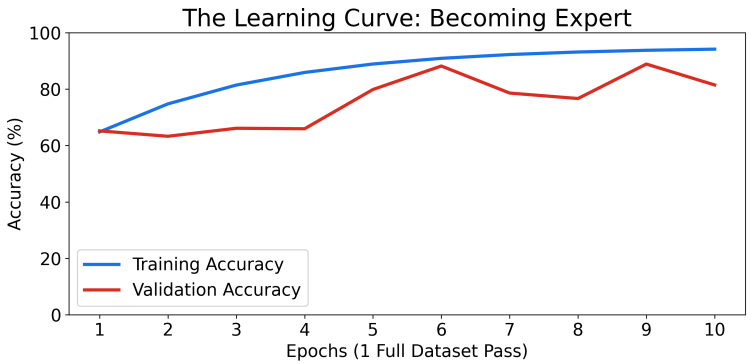

> 💡 **[MISSION 4 CLUE]:**
> ในแล็บวันนี้ เราจะตั้งค่าการฝึกฝนไว้ที่ **10 Epochs** สังเกตดูกราฟความแม่นยำ (Accuracy) ที่จะค่อยๆ พุ่งสูงขึ้นเรื่อยๆ!

📏 7. Data Consistency: The Golden Rule

กฎเหล็กของการทำ AI: "ข้อมูลตอนสอบ ต้องมีขนาดเท่ากับตอนเรียน"

- หากเราสอน AI ด้วยภาพขนาด 32x32 พิกเซล ตอนเอาไปใช้งานจริง ภาพที่ส่งให้มันทายก็ต้องถูกย่อเป็น 32x32 เช่นกัน
- **ในมิติของเสียง (Audio Data):** เราต้องควบคุม "จำนวนจุดข้อมูล (Data Points)" ให้เป๊ะ!

> 💡 **[MISSION 5 CLUE]:**
> ชุดข้อมูลเสียงมีความยาวคำละ **1 วินาที** > ระบบเสียงของเรามี Sampling Rate ไว้ที่ **16,000 Hz** (จุดต่อวินาที)
>
> *คำถามคือ: ตอนนักศึกษาอัดเสียงตัวเองมาทดสอบ จะต้องตัดเสียงให้เหลือความยาวกี่จุดข้อมูล จึงจะป้อนให้ AI ได้?*

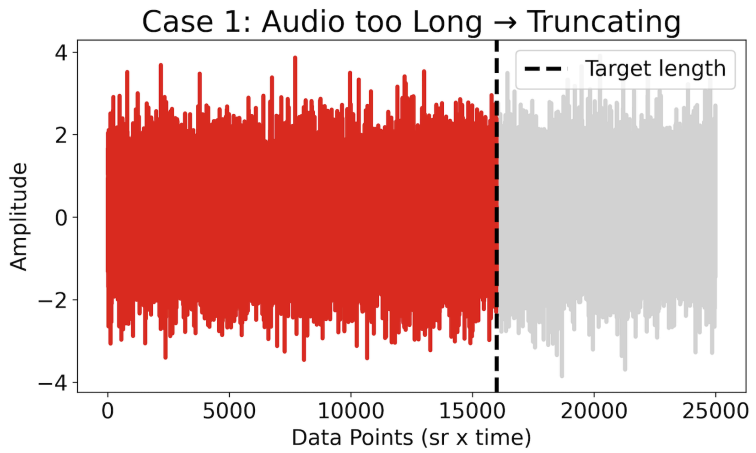

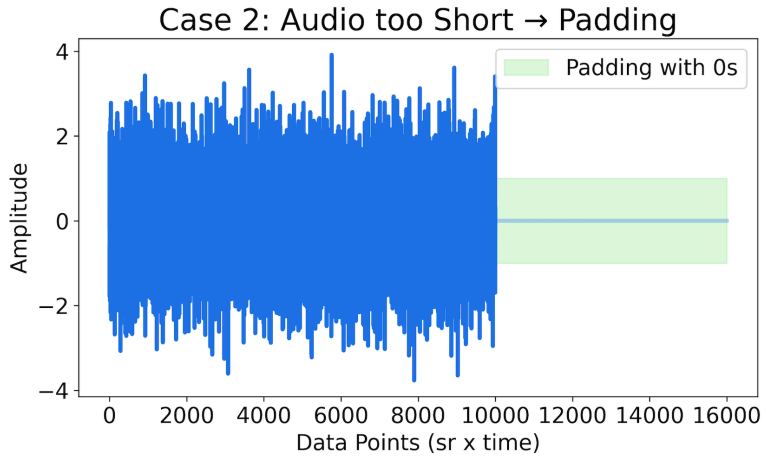

🚀 Mission Briefing (Lab 03)

ภารกิจปลุกชีพสมองกลของคุณ

1. **[Mission 1]** โหลดชุดข้อมูลเสียงพูด 8 คำสั่ง (Mini Speech Commands)
2. **[Mission 2]** แปลงคลื่นเสียงเป็น **Mel-spectrogram** ให้สอดคล้องกับหูมนุษย์
3. **[Mission 3]** สร้างโครงสร้าง **CNN** และกำหนด Output Layer ให้ถูกต้อง
4. **[Mission 4]** สั่งรันกระบวนการ **Training** เพื่อเฝ้าดู AI พัฒนาความฉลาด
5. **[Mission 5]** เปิดไมโครโฟน อัดเสียงตัวเอง แล้วพิสูจน์ว่าสมองกลที่คุณสร้างขึ้นมา "ฟังคุณรู้เรื่อง" หรือไม่!

Ready? Open Colab, find the `### YOUR CODE HERE ###` and let's build AI! 👩‍💻👨‍💻